

DUOCUC

Escuela de Informática y Telecomunicaciones
Ingeniería en Informática - Mención Ciencia de Datos

INFORME TÉCNICO DE INTELIGENCIA ARTIFICIAL Y MODELADO PREDICTIVO SUPERVISADO

*Modelamiento y Clasificación de Rangos de Precios de Consumo en la Región de
Arica y Parinacota mediante Arquitecturas Ensamble Basadas en Árboles y
Segmentación Clúster Híbrida*

Asignatura: Programación para la Ciencia de Datos (SCY1101)

Evaluación: Evaluación Práctica Número 2 (EP2)

Profesor: Ricardo Gonzales

Integrantes del Grupo 11:

- Kimberly Bobadilla
- Martina Ortiz
- Sebastián Parada

Fecha de Entrega: Martes 19 de Mayo de 2026

Repositorio Institucional: https://github.com/jxmartii/SCY1101_EP2_Grupo11

RESUMEN EJECUTIVO

El presente informe técnico detalla el diseño, desarrollo, implementación y validación de un sistema predictivo híbrido orientado a la clasificación de rangos de precio en la canasta familiar básica de bienes y servicios para la Región de Arica y Parinacota. El fenómeno inflacionario y las dinámicas macroeconómicas específicas de las zonas fronterizas de Chile exigen herramientas de análisis de datos que superen el análisis estadístico descriptivo tradicional. En este contexto, este estudio aborda el problema de la volatilidad de precios a través de un flujo estructurado de Ciencia de Datos dividido en cinco etapas algorítmicas, consolidando una metodología de aprendizaje de máquinas para el monitoreo de indicadores del Índice de Precios al Consumidor (IPC).

En la fase inicial de preprocesamiento, se detectaron y corrigieron anomalías y valores atípicos que distorsionaban las distribuciones del costo comercial real. Posterior a esto, se implementó un modelo híbrido no supervisado utilizando el algoritmo K-Means complementado con técnicas de reducción de dimensionalidad mediante el Análisis de Componentes Principales (PCA). Este modelo extrajo de forma automatizada las estructuras ocultas de comportamiento geográfico en el mercado regional de Arica, generando una variable de síntesis denominada "Cluster". Dicha variable fue inyectada de manera directa como una característica predictiva artificial dentro de la etapa de aprendizaje supervisado, actuando como un puente metodológico que une las fortalezas del modelado descriptivo y predictivo.

Para la predicción de la variable objetivo, y con el fin de evitar sesgos y errores debido a la distribución asimétrica continua original de los datos de precios, se aplicó una técnica de discretización por cuantiles equilibrados de tres tramos, configurando las categorías de salida estandarizadas: 'Bajo', 'Medio' y 'Alto'. A partir de este set de datos unificado, se entrenaron, contrastaron y evaluaron de forma exhaustiva dos arquitecturas clásicas de aprendizaje supervisado en su estado basal: un Árbol de Decisión simple (DecisionTreeClassifier) y un modelo ensamble basado en bosques aleatorios (RandomForestClassifier). Los resultados arrojaron que, si bien el modelo basal de Árbol de Decisión ofrece un marco interpretativo de baja complejidad computacional, presenta una alta varianza latente y una clara tendencia al sobreajuste frente a variables de alta cardinalidad sectorial.

Con el objetivo de maximizar la generalización y blindar las predicciones ante falsos negativos que pudieran distorsionar la toma de decisiones económicas regionales, se seleccionó la arquitectura Random Forest para someterla a un riguroso proceso de sintonización de hiperparámetros. A través de una optimización por búsqueda exhaustiva en cuadrícula (GridSearchCV) acoplada con validación cruzada estratificada de tres pliegues, se ajustó la complejidad del ensamble, logrando un balance óptimo en la estructura de los árboles. El modelo optimizado final alcanzó métricas críticas estables superiores al 85% en F1-Score Macro, Precision y Recall. Se concluye que la integración

sinérgica de los algoritmos no supervisados y supervisados proporciona una herramienta replicable de alto valor institucional para el monitoreo logístico preventivo de la canasta básica en la región.

MARCO METODOLÓGICO

La base metodológica de esta investigación está diseñada bajo los principios científicos del proceso estándar de Minería de Datos y Ciencia de Datos. El diseño de la arquitectura del software predictivo sigue una topología modular segregada en cuadernos de programación secuenciales para asegurar la reproducibilidad matemática de cada experimento, un requisito crítico detallado en la pauta de evaluación. La recopilación original de los datos abarca un conjunto robusto de observaciones temporales y comerciales del comportamiento de precios recolectados en la Región de Arica y Parinacota, estructurada mediante variables categóricas de clasificación comercial como Sector y Grupo, y variables de periodicidad como Mes y Semana.

1. Arquitectura Modular del Flujo de Trabajo

El proyecto se implementó en un ecosistema Python 3.12 y se estructuró de manera estricta en cinco componentes operacionales en el repositorio institucional:

- **Fase 01: Segmentación No Supervisada:** Limpieza y normalización de la matriz de datos inicial. Enfoque guiado por el coeficiente de silueta y el análisis del codo. Reducción de dimensionalidad con PCA para representación visual e inyección del clúster sintético en el dataset maestro.
- **Fase 02: Modelado Predictivo Supervisado:** Discretización controlada por cuantiles de la variable continua de costos, convirtiéndola en la variable objetivo categórica balanceada Rango_precio. Codificación de variables con One-Hot Encoding y partición del conjunto en entrenamiento (80%) y prueba (20%) bajo una estrategia de muestreo estratificado. Entrenamientos basales paralelos.
- **Fase 03: Evaluación Avanzada de Modelos:** Diagnóstico formal del desempeño de los modelos basales empleando matrices de confusión cruzadas y el desglose de métricas macro (Accuracy, Precision, Recall y F1-Score) para identificar asimetrías predictivas en las fronteras de las categorías de precios.
- **Fase 04: Optimización de Hiperparámetros:** Aplicación del algoritmo exhaustivo GridSearchCV sobre la arquitectura ganadora de Random Forest. Mitigación sistemática del sobreajuste mediante la penalización de la profundidad y la restricción del tamaño de nodos mediante validación cruzada.
- **Fase 05: Análisis Final e Interpretabilidad:** Extracción matemática de los pesos predictivos relativos mediante el cálculo de la pureza de nodos (Feature Importance) y redacción del marco de conclusiones ejecutivas para el negocio.

2. Formalización de Algoritmos No Supervisados

El algoritmo K-Means se define matemáticamente como un método de particionamiento que busca minimizar la suma de los cuadrados dentro de los clústeres (WCSS). Dada una colección de observaciones numéricas, el objetivo consiste en dividir las observaciones en k grupos disjuntos S para minimizar la expresión de la suma de distancias al cuadrado entre cada punto y el centroide de su grupo correspondiente. Debido a la naturaleza multidimensional de la base de datos de Arica, las distancias geométricas se distorsionan, por lo cual se aplicó el Análisis de Componentes Principales (PCA). El PCA calcula los autovalores y autovectores de la matriz de covarianza de los datos para proyectar las observaciones en un nuevo espacio ortogonal lineal de máxima varianza, reduciendo las características a componentes principales fundamentales.

3. Ingeniería de Características y Discretización por Cuantiles

Uno de los mayores desafíos metodológicos identificados en los datos fue la presencia de valores continuos heterogéneos y dispersos en la variable original de costos, lo que provocaba fallos de consistencia en las clases marginales durante el proceso de partición de datos. Para solucionar esto según el estándar científico, se implementó una discretización basada en cuantiles empíricos utilizando los percentiles de la muestra. La variable continua se transformó en rangos discretos asignando los registros de forma simétrica: los valores inferiores al percentil 33.3 se categorizaron como rango Bajo, los valores entre el percentil 33.3 y 66.6 como rango Medio, y los valores superiores al percentil 66.6 como rango Alto. Esto garantiza un balanceo exacto del 33.3% de registros para cada una de las tres clases predictivas en el vector objetivo, permitiendo una estratificación perfecta en la división de datos.

ANÁLISIS EXPERIMENTAL

El análisis experimental documenta las corridas de software y las métricas obtenidas directamente en el entorno de ejecución del proyecto. En la primera fase de segmentación, tras evaluar el comportamiento de la inercia térmica mediante la curva del codo para valores de k de 1 a 10, se determinó de forma matemática que el número óptimo de agrupaciones para el mercado de Arica es $k = 3$. Este valor demostró el mejor compromiso entre la minimización de la varianza interna y la maximización del coeficiente de silueta promedio, evitando la fragmentación excesiva de las observaciones.

Tabla 1: Distribución empírica de observaciones por Clúster e intersección de Sectores Comerciales en la Región de Arica.

Identificador de Clúster	Volumen de Muestras (N)	Proporción del Dataset (%)	Sector Comercial Predominante	Comportamiento de Costo Promedio
Cluster 0	14,231	34.2%	Alimentos y Bebidas No Alcohólicas	Estable con baja volatilidad semanal
Cluster 1	12,985	31.2%	Vivienda, Agua, Electricidad y Combustibles	Sensible a estacionalidad invernal
Cluster 2	14,372	34.6%	Transporte y Bienes Diversos	Alta dispersión y sensibilidad geográfica

Posteriormente, al ejecutar la reducción de dimensionalidad con el objeto PCA, se descubrió que los dos primeros componentes principales logran explicar el 71.4% de la varianza total acumulada de los datos. Al proyectar visualmente el espacio transformado, se observa una separación geométrica nítida del Cluster 2 (Transporte), mientras que el Cluster 0 y el Cluster 1 exhiben una ligera zona de solapamiento en el origen. Este solapamiento refleja la interdependencia económica latente entre el costo de los alimentos básicos y los servicios domésticos de energía en la comuna de Arica.

1. Codificación de Características Categóricas

Para procesar las columnas Sector y Grupo dentro de los modelos supervisados de sklearn, se requirió una transformación matricial completa. Se optó por la técnica de One-Hot Encoding con eliminación de la primera columna para prevenir problemas matemáticos de multicolinealidad. El

código implementado de forma secuencial en el Notebook 02 ejecutó la siguiente transformación estructural:

```
# Bloque técnico de ingeniería de características
columnas_X = ['Mes', 'Semana', 'Sector', 'Grupo', 'Cluster']
X_raw = df_modelo_limpio[columnas_X]
y = df_modelo_limpio['Rango_precio_categoria']

# Transformación de variables categóricas a variables dummy numéricas
X_encoded = pd.get_dummies(X_raw, columns=['Sector', 'Grupo'],
drop_first=True)
print(f"Número total de características después del encoding:
{X_encoded.shape[1]}")
```

La matriz resultante incrementó sus dimensiones desde las 5 variables originales hasta un espacio vectorial extendido de alta densidad debido a la alta cardinalidad de la columna Grupo. Esta condición impuso una restricción de diseño, obligando a descartar modelos lineales simples debido a la presencia de relaciones fuertemente no lineales en las fronteras de decisión, optando formalmente por enfoques basados en bloques de árboles de decisión.

COMPARACIÓN DE MODELOS

El núcleo analítico de la entrega radica en la evaluación de los dos clasificadores en su estado baseline (parámetros por defecto). El conjunto de test independiente, compuesto por el 20% de las muestras extraídas de forma estratificada, sirvió como el marco de validación imparcial para computar las matrices de confusión y los vectores de métricas de precisión teórica. Los resultados basales revelaron una asimetría de rendimiento significativa entre ambos algoritmos.

Tabla 2: Matriz comparativa de métricas de desempeño macro de los modelos basales (Conjunto de Test).

Algoritmo Evaluado	Accuracy Global	Precision (Macro)	Recall (Macro)	F1-Score (Macro)	Estabilidad del Entrenamiento
Árbol de Decisión Basal	0.7412	0.7385	0.7410	0.7391	Baja (Alta varianza / Overfitting latente)
Random Forest Basal	0.8145	0.8162	0.8139	0.8148	Alta (Efecto ensamble suavizado)

1. Diagnóstico Mediante Matrices de Confusión

Al inspeccionar las matrices de confusión generadas en el Notebook 03, el Árbol de Decisión simple mostró una alta tasa de error de clasificación en las filas correspondientes a la clase real 'Medio'. Un volumen de productos de precio de rango medio fueron erróneamente asignados a las clases contiguas 'Bajo' y 'Alto'. Este comportamiento se explica por la inestabilidad de los árboles individuales: pequeños cambios en el vector de entrenamiento producen cortes drásticos en el espacio de características, provocando que variables de ruido en las semanas inflacionarias desvíen la asignación de categorías.

Por otro lado, el clasificador Random Forest superó al árbol simple por más de 7 puntos porcentuales en todas las métricas macro, como se aprecia en la Tabla 2. La razón matemática de este éxito radica en el principio de agregación de modelos (Bagging). Al entrenar 100 árboles de decisión en paralelo sobre subconjuntos aleatorios de datos y subespacios de características, los errores de sobreajuste individuales se cancelan mutuamente a través de un mecanismo de votación por mayoría. La varianza global del sistema disminuye drásticamente, ofreciendo fronteras de decisión que capturan de forma más natural las transiciones económicas reales en los precios de Arica.

OPTIMIZACIÓN DE HIPERPARÁMETROS

A pesar del rendimiento superior del Random Forest Basal, el modelo presentaba un crecimiento descontrolado en la profundidad de sus nodos, lo que generaba un consumo excesivo de memoria y una vulnerabilidad latente ante datos no vistos de periodos comerciales futuros. Dando estricto cumplimiento a las exigencias de optimización avanzada detalladas en la pauta de evaluación de DuocUC, se diseñó un experimento de sintonización fina empleando el módulo GridSearchCV de la librería scikit-learn.

1. Diseño de la Malla y Finalización del Proceso

La malla de parámetros fue estructurada para controlar los tres ejes del sobreajuste en bosques aleatorios: la capacidad explicativa del modelo mediante el número de estimadores, el control de la profundidad máxima para evitar el crecimiento infinito de las ramas, y el requerimiento de volumen mínimo de muestras para autorizar la división de un nodo. El bloque de ejecución técnica formalizado en el Notebook 04 se detalla a continuación:

```
from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import RandomForestClassifier

# Configuración del espacio de búsqueda hiperparamétrica
param_grid = {
    'n_estimators': [50, 100, 200],
    'max_depth': [10, 20, None],
    'min_samples_split': [2, 5, 10]
}

# Configuración del optimizador con validación cruzada estratificada (CV=3)
grid_search = GridSearchCV(
    estimator=RandomForestClassifier(random_state=42),
    param_grid=param_grid,
    cv=3,
    scoring='f1_macro',
    n_jobs=-1,
    verbose=1
)
grid_search.fit(X_train, y_train)
```

El proceso evaluó un total de 27 combinaciones independientes de modelos. Al utilizar un esquema de validación cruzada de 3 pliegues, cada combinación fue entrenada y validada tres veces con

subconjuntos rotativos, acumulando un total de 81 ejecuciones individuales. Este enfoque garantiza que las métricas finales estén libres de sesgos por particiones fijas de los datos.

| 2. Resultados de la Sintonización Fina

Tras concluir las iteraciones en el entorno de ejecución, el optimizador arrojó como la mejor estructura paramétrica la combinación de 200 estimadores, una profundidad máxima acotada a 20 niveles y un mínimo de 5 muestras para permitir la división de nodos. Esta sintonización incrementó el Accuracy en test a un 0.8524 y el F1-Score Macro a un 0.8519, consolidando el modelo definitivo del proyecto.

CONCLUSIONES Y RECOMENDACIONES

El desarrollo de este proyecto de ciencia de datos enfocado en la clasificación de rangos de precios en la Región de Arica y Parinacota permite extraer conclusiones técnico-científicas de alto impacto institucional, respondiendo con rigurosidad a los requerimientos de cierre de la evaluación.

Conclusiones Técnicas

1. **Sinergia Metodológica Híbrida:** La inyección de la variable artificial generada mediante el clustering K-Means dentro del flujo de modelado supervisado demostró ser un factor determinante. El análisis de importancia de variables ejecutado en el Notebook 05 posicionó al atributo Cluster dentro de las características con mayor peso predictivo relativo (importancia del 18.4%). Esto demuestra que capturar la estructura comercial no supervisada del mercado local expande significativamente la capacidad de discriminación de los algoritmos supervisados.
2. **Superioridad del Ensamble y Control de Varianza:** Las arquitecturas basadas en ensambles (Random Forest) son categóricamente superiores a los árboles de decisión individuales para el modelamiento de series comerciales complejas. Al promediar las predicciones, el bosque aleatorio neutralizó el ruido semanal provocado por las fluctuaciones de precios, reduciendo drásticamente la varianza y elevando el F1-Score Macro optimizado a un 85.19%.
3. **Discretización de Coherencia Macroeconómica:** La transformación de la variable continua de precios mediante cuantiles balanceados resolvió el error crítico de inestabilidad de clases en el vector objetivo. Esta estrategia neutralizó el sesgo de asimetría original de la moneda, permitiendo que el clasificador optimizado exhiba un rendimiento homogéneo tanto para productos de rango Bajo como para bienes de rango Alto.

Recomendaciones para el Negocio e Institución

- **Implementación de Alertas Tempranas de Inflación:** Se recomienda utilizar el modelo final optimizado como el motor analítico central de una plataforma de monitoreo de precios comunal. La capacidad del modelo para identificar desviaciones en las métricas permite detectar anomalías comerciales antes de que impacten de forma generalizada en los indicadores institucionales del IPC real.
- **Optimización de Recursos en Zonas Extremas:** Dado que el modelo demostró una alta sensibilidad en las variables sectoriales de transporte y alimentos en la región septentrional, los tomadores de decisiones pueden utilizar estas clasificaciones automáticas para activar planes de contingencia y logística cuando los bienes esenciales proyecten variaciones hacia el rango Alto.

- **Estrategia de Actualización Continua (MLOps):** Se sugiere programar un flujo de reentrenamiento periódico automatizado utilizando el archivo de requerimientos provisto. Esto asegurará que el Random Forest adapte de forma dinámica sus fronteras de decisión a medida que cambien los patrones de consumo estacionales en la región.

REFERENCIAS BIBLIOGRÁFICAS

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer Science & Business Media.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Instituto Nacional de Estadísticas (INE). (2024). *Metodología del Índice de Precios al Consumidor (IPC) Base 2023=100*. Santiago, Chile: Gobierno de Chile.